Лабораторная работа 3. Обучение с учителем. Регрессия. Ансамблевое обучение. Нейронные сети.

В рамках лабораторной работы выполняется сравнение точности различных методов машинного обучения в рамках решения задачи регрессии для прогнозирования будущих значений целевой переменной. Для временного ряда с фиксированным шагом будущее значение может быть получено путём обучения модели со сдвигом на 1 шаг, так чтобы входному тензору $\mathbf{X}_t$ соответствовал выходной тензор $\mathbf{Y}_{t+1}$ на этапе обучения, т.е., модель должна учиться находить соответствие между текущим выходным значением и предыдущими по отношению к нему (в плане момента времени) входными значениями.

Датасет **Lab3_Dataset.xlsx** включает в себя набор из 5 признаков (по вариантам) и столбец значений целевой переменной ***y***. При необходимости, исходный набор может быть дополнен по желанию в ходе выполнения работы дополнительными синтетическими признаками (производная, скользящее среднее и т.п.).

1. Выполнить предварительную обработку и решить задачу регрессии базовыми методами статистики и оптимизации.

1.1. Отобразить на едином графике все признаки и целевую переменную.

1.2. Выполнить разбиение исходного датасета на train/val/test выборки для обучения, валидации и тестирования, соответственно. Определить пропорцию разбиения самостоятельно в ходе решения, выделить на train не менее 50%. При нормировке/масштабировании (а также при их обращении для анализа результатов), использовать сохранённые параметры масштабирования train-выборки для всех 3-х выборок. Самостоятельно определить вариант нормализации/масштабирования.

1.3. Рассчитать матрицу взаимных корреляций между признаками и целевой переменной.

1.4. Для признака с наибольшей по модулю корреляцией с целевой переменной построить модель парной линейной регрессии.

1.5. Построить модель множественной регрессии для всех признаков.

1.6. Проанализировать вид графика исходных данных, подобрать вид аппроксимирующей функции, построить модель нелинейной регрессии с помощью curve_fit() из библиотеки SciPy с использованием всех переменных.

2. Выполнить прогнозирование с помощью одиночных методов машинного обучения. Для параметрических методов определить оптимальные гиперпараметры.

2.1. Решить задачу регрессии с помощью метода K ближайших соседей - K-Nearest Neighbors (KNN).

2.2. Решить задачу регрессии с помощью машины опорных векторов (SVM).

2.3. Решить задачу регрессии с помощью одиночного дерева принятия решений (Decision Tree).

3. Для решения задачи с помощью ансамблевых методов могут быть использованы библиотеки scikit-learn или xgboost (разработана специально для параллелизации алгоритмов бустинга). Определить оптимальные гиперпараметры.

3.1. Решить задачу регрессии с помощью случайного леса (Random Forest).

3.2. Решить задачу регрессии с помощью бэггинга (bagging).

3.3. Решить задачу регрессии с помощью градиентного бустинга (gradient boosting).

4. Разработать нейронные сети для решения задачи прогнозирования. Решить задачу для 2-х вариантов прогноза – на 1 шаг вперёд, на 7 шагов вперёд. Для создания модели для множественного прогноза выходной тензор должен быть дополнен дополнительным измерением. Для одношагового прогноза каждому набору входных данных на этапе обучения в фиксированный момент времени соответствует единственное выходное значение. Для многошагового прогноза каждому набору входных данных на этапе обучения в фиксированный момент времени должен соответствовать вектор длины 7, каждое последующее значение которого должно быть сдвинуто на 1 шаг по сравнению с предыдущим: $\mathbf{Y}_{t+1} = \{y_{t+1}; y_{t+2}; \ldots; y_{t+7}\}$

Нейросетевые методы реализуются с помощью библиотек Keras или PyTorch (по выбору). После реализации нейросетевых методов сравнить их число их внутренних параметров, а также построить графики кривых обучения (зависимость значений используемых метрик и значения функции потерь от эпохи обучения).

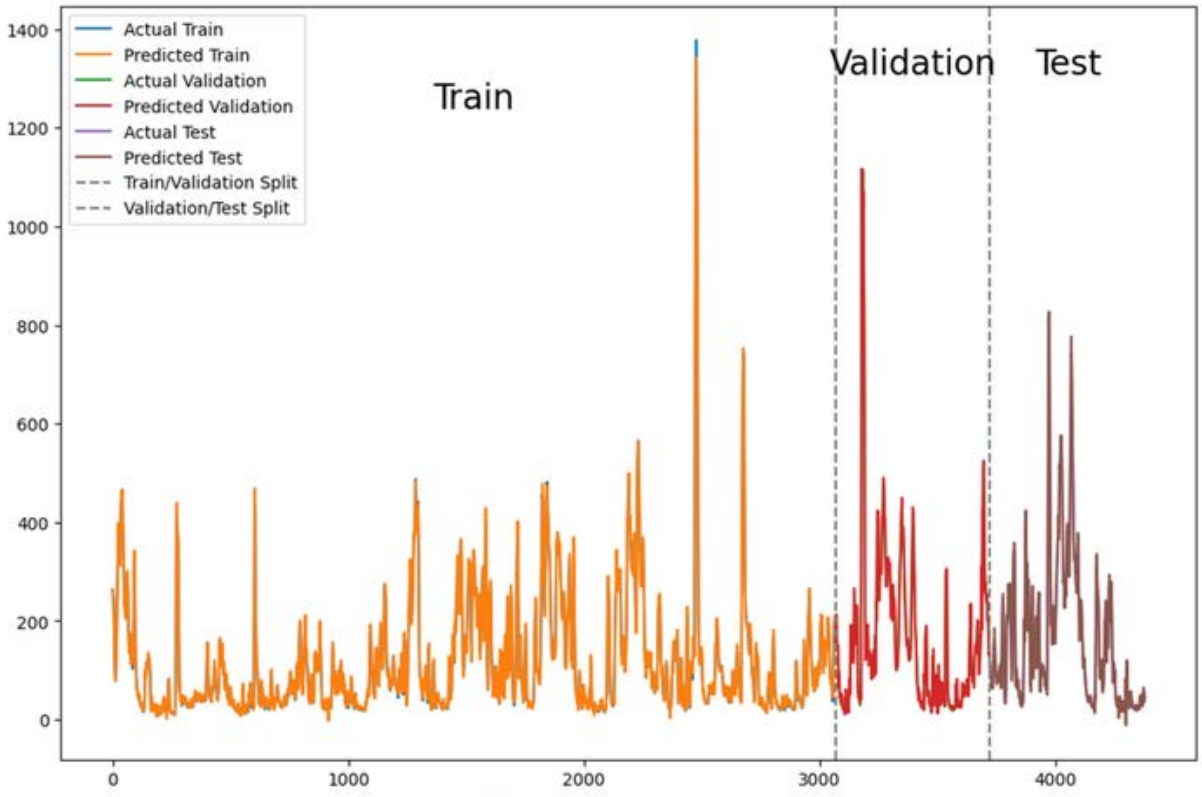
4.1. Решить задачу регрессии с помощью однослойного линейного персептрона с функцией активации. Определить оптимальную функцию активации, гиперпараметры, функцию потерь и метод оптимизации.

4.2. Решить задачу регрессии с помощью многослойного персептрона. Определить оптимальное число слоёв, функцию потерь, гиперпараметры и метод оптимизации.

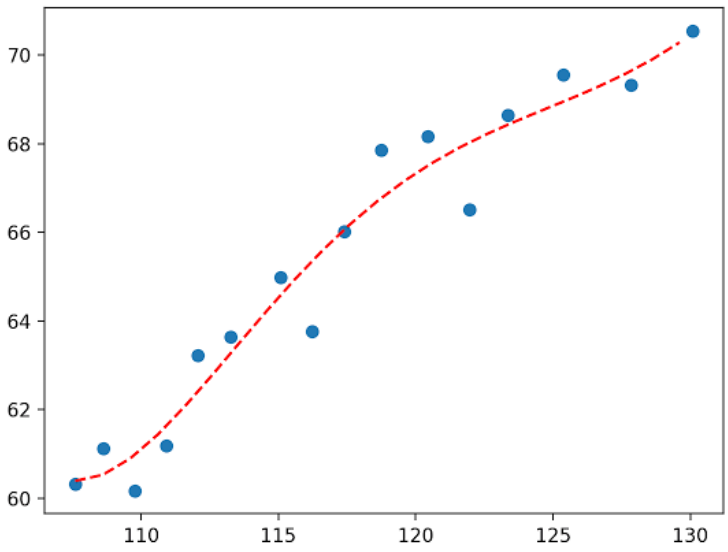
4.3. Разработать глубокую нейронную сеть произвольной архитектуры, способную решить задачу регрессии, и позволяющую получить близкие или превосходящие метрики по сравнению с многослойным персептроном и ансамблевыми методами. Самостоятельно определить число слоёв, конкретные виды слоёв, их порядок расположения, функции активации, гиперпараметры, функцию потерь.

5. Выполнить обработку полученных результатов, дать им интерпретацию и определить методы, давшие наилучшие и наихудшие результаты, объяснить причины.

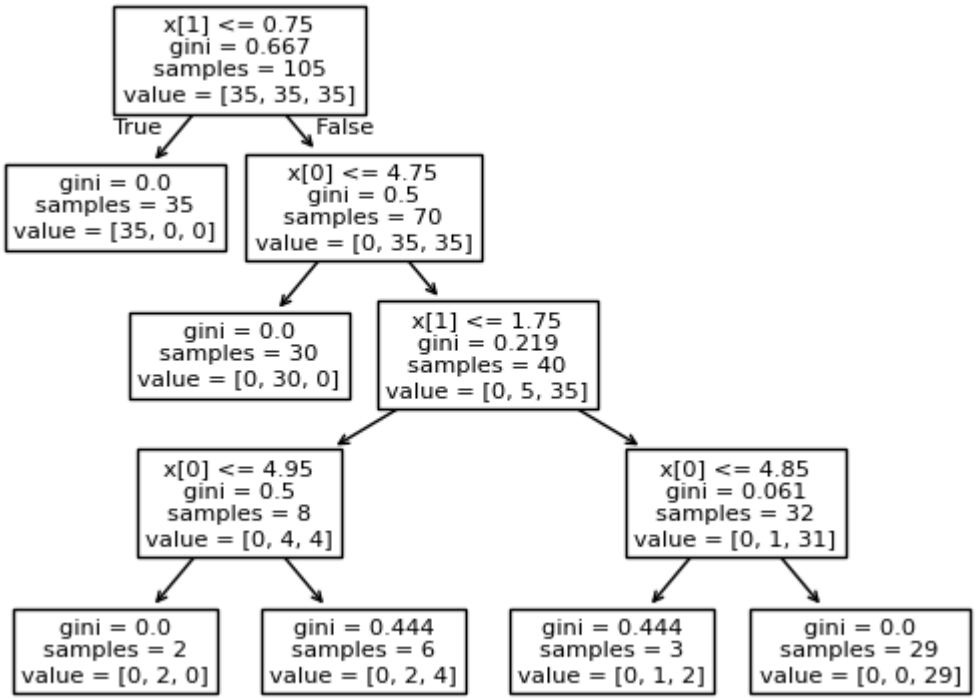
5.1. Для всех рассмотренных методов (где возможно) построить график по следующему шаблону, а также аналогичный график для разности между реальными значениями и прогнозом:



5.2. Для линейной, множественной и нелинейной регрессии построить график аппроксимирующей функции, исходных данных и прогноза (отобразить разными цветами).



5.3. Для методов на основе деревьев построить дендрограмму решения:



5.4. Сравнить результаты работы методов между собой на основе метрик средней абсолютной ошибки (MAE), среднеквадратической ошибки (MSE), коэффициента корреляции для **тестовой** выборки. Провести сравнение для случаев наличия и отсутствия нормализации/масштабирования при обучении.

5.5. Свести результаты для метрик для всех методов в итоговую таблицу, экспортировать таблицу в файл **results_Comparison.xlsx**.

5.6. Определить наилучшие и наихудшие методы, дать интерпретацию результатов.